

INFORME EXPERTO SOBRE MACHINE LEARNING EN CIBERSEGURIDAD: ANÁLISIS, EXTRACCIÓN Y EXPLOTACIÓN DE VULNERABILIDADES DE MODELOS

Introducción y Alcance del Análisis

El panorama de amenazas cibernéticas ha evolucionado significativamente, impulsado por una escala y sofisticación que exceden la capacidad de los sistemas de detección tradicionales basados en firmas.¹ En este contexto, el *Machine Learning* (ML) y el *Deep Learning* (DL) se han consolidado como herramientas esenciales para la ciberseguridad, transformando las metodologías defensivas al permitir el análisis de *Big Data* de seguridad, la detección de anomalías y la automatización de la respuesta.

Este informe proporciona un análisis metodológico y exhaustivo del ML en la ciberseguridad, diseñado específicamente para un futuro analista de seguridad (SOC/Threat Analyst) con una base sólida en el análisis de sistemas y la explotación de vulnerabilidades. Se cubrirá el ciclo de vida completo de un modelo de ML, desde sus fundamentos algorítmicos y la ingeniería de características, hasta su integración en operaciones de seguridad automatizadas (SOAR) y, fundamentalmente, los desafíos ofensivos inherentes a la defensa de estos sistemas contra ataques adversarios (*Adversarial ML*).

El Imperativo de la IA en la Ciberdefensa

La aplicación del ML permite a las organizaciones ser más proactivas, eficientes y adaptables.¹ Ante el aumento desenfrenado del

malware, la ingeniería social y las explotaciones, y la aparición de amenazas impulsadas por la IA, los equipos de seguridad deben escalar su defensa. El ML proporciona esa escalabilidad al automatizar y acelerar la respuesta a incidentes, mejorar la detección y predicción de amenazas, y aumentar la precisión de los verdaderos positivos.¹

1. Fundamentos y Taxonomía del ML en Seguridad

El éxito de la IA en la ciberseguridad depende de una comprensión clara de los paradigmas de aprendizaje y de la selección del algoritmo adecuado para el tipo de dato de seguridad en cuestión.

1.1. Tipos de Aprendizaje Aplicables: Supervisado, No Supervisado y por Refuerzo

Los algoritmos de ML se clasifican según cómo interactúan con los datos y el objetivo de la tarea de aprendizaje:

Aprendizaje Supervisado (*Supervised Learning*)

Este paradigma se basa en conjuntos de datos previamente etiquetados, donde cada muestra de entrada está asociada con una etiqueta de salida deseada (por ejemplo, "malware" o "benigno"). Su principal aplicación es la **Clasificación**. En ciberseguridad, es ideal para tareas donde el conocimiento previo está disponible, como la detección de *malware* conocido, la clasificación de intentos de *phishing* o la categorización de tráfico de red en función de patrones de ataque previamente identificados (por ejemplo, DoS frente a tráfico legítimo). El modelo aprende a mapear las características de entrada a una etiqueta de salida predefinida.

Aprendizaje No Supervisado (*Unsupervised Learning*)

El ML no supervisado trabaja con datos que carecen de etiquetas de salida, buscando

patrones intrínsecos, estructuras o agrupaciones (*clustering*) dentro del conjunto de datos. Su aplicación más crítica en seguridad es la **Detección de Anomalías**.

Esta metodología es fundamental para establecer una línea de base (*baselining*) del comportamiento normal de los sistemas, los usuarios y la red. Al identificar las desviaciones de este comportamiento normal, permite la detección de amenazas de **Día Cero**¹ o ataques internos para los que no existe una firma o etiqueta previa. Esta capacidad de identificar desviaciones sin requerir conocimiento previo del ataque es lo que convierte al aprendizaje no supervisado en una defensa vital contra amenazas emergentes.

Aprendizaje por Refuerzo (*Reinforcement Learning* - RL)

El aprendizaje por refuerzo implica que un agente aprende a tomar una secuencia de decisiones dentro de un entorno dinámico para maximizar una recompensa acumulada. Si bien es menos común en la detección actual, el RL representa el futuro de la **Respuesta Adaptativa**. Puede ser utilizado para optimizar automáticamente las políticas de seguridad (por ejemplo, ajustar reglas de *firewall* o parámetros de sistemas de aislamiento) al aprender qué acciones de contención maximizan la seguridad y minimizan la interrupción del servicio. En un entorno de amenazas impulsadas por IA, el RL ofrece la capacidad de escalar una respuesta más allá de los *playbooks* estáticos de SOAR.

1.2. Algoritmos Centrales: SVM, Random Forests, y Redes Neuronales

La elección del algoritmo debe reflejar la estructura y el volumen de los datos que se procesan.

Máquinas de Vectores de Soporte (SVM) y Random Forests (RF)

Los algoritmos tradicionales de ML, como las Máquinas de Vectores de Soporte (SVM) y los Bosques Aleatorios (Random Forests), continúan siendo valiosos, especialmente para el análisis de metadatos o características extraídas de logs y tráfico que se presentan en un formato tabular estructurado.

- **SVM:** Es un clasificador supervisado potente, particularmente efectivo en la clasificación binaria (ej., malicioso vs. benigno) al buscar el hiperplano óptimo que separe las clases

en un espacio de características de alta dimensión.

- **Random Forests y XGBoost:** Son métodos de ensamblaje basados en árboles de decisión.³ Ofrecen alta precisión y son intrínsecamente más robustos frente al *overfitting* en comparación con un solo árbol. Son ampliamente utilizados en la detección de fraudes³ y son la columna vertebral para la clasificación de *malware* basada en características estáticas de archivos o metadatos de red, ya que proporcionan una interpretabilidad de características superior a los modelos de *Deep Learning*.

Redes Neuronales Recurrentes (RNN/LSTM) y Convolucionales (CNN)

Las arquitecturas de *Deep Learning* son la respuesta a la incapacidad de las tecnologías tradicionales de detección para enfrentar amenazas avanzadas.² Estos modelos son capaces de aprender jerarquías de características automáticamente y son ideales para datos no estructurados o secuenciales.

- **Redes Neuronales Recurrentes (RNN/LSTM):** Estas arquitecturas son óptimas para procesar datos secuenciales y series temporales.⁵ En ciberseguridad, son cruciales para:
 1. **Análisis de Secuencias de Eventos:** Modelar el orden y la temporalidad de las llamadas al sistema (*syscalls*) en *endpoints* o las secuencias de actividad de un usuario. Esto es fundamental para la Detección de Comportamiento de Usuarios y Entidades (UEBA), anticipando movimientos laterales o intrusiones basadas en el orden de las acciones.²
- **Redes Neuronales Convolucionales (CNN):** Originalmente diseñadas para datos en formato de cuadrícula como imágenes y video⁵, las CNN se adaptan en seguridad para:
 1. **Análisis de Binarios:** Una secuencia de bytes de un archivo ejecutable puede ser tratada como una "imagen" o *heatmap*. Las capas convolucionales aprenden patrones espaciales (como secuencias de *opcodes* o estructuras de código malicioso) en el binario sin requerir una ingeniería de características manual exhaustiva.
 2. **Análisis de Tráfico:** Convertir los flujos de paquetes en representaciones matriciales donde las correlaciones espaciales entre los datos de encabezado y la carga útil revelan patrones de ataque o tráfico anómalo.

El éxito en ciberseguridad se vincula a la capacidad de emparejar la estructura de los datos de seguridad (logs, binarios, *time-series*) con la arquitectura neuronal adecuada (CNN para patrones espaciales, RNN para la temporalidad).

2. Ciclo de Vida del Modelo y Aplicaciones Clave

La implementación práctica del ML en un entorno de seguridad comienza mucho antes de alimentar los datos al algoritmo, siendo la preparación de los datos el factor limitante más común en el rendimiento del modelo.

2.1. Extracción de Características (*Feature Engineering*): La Arquitectura del Dato de Seguridad

El *Feature Engineering* (FE) es la etapa fundamental en la cual los datos de seguridad brutos—sean logs, paquetes o binarios—se transforman en un formato numérico y significativo que el modelo de ML puede interpretar.⁶ Esta transformación es esencial porque la precisión del análisis depende directamente de la calidad y la representatividad de las *features* utilizadas.⁶ Incluso los algoritmos más sofisticados fallarán si la entrada no es de alta calidad (" *garbage in, garbage out*").⁶

El verdadero desafío del FE no es la técnica en sí misma (como la codificación o la normalización), sino el conocimiento del dominio de la ciberseguridad. El analista debe saber *qué* características de un evento de seguridad son indicativas de un ataque real.

Tabla 3: Feature Engineering para Datos de Seguridad

Tipo de Dato de Seguridad	Features de Ejemplo	Técnica de Procesamiento	Justificación
Tráfico de Red (Flujos/Paquetes)	Duración de la conexión, Entropía de Shannon de la carga útil, Proporción Paquetes E/S, Latencia media.	Normalización, Cálculo de Entropía, Binning/Bucketizing .	La Entropía de Shannon ayuda a identificar tráfico cifrado o <i>packing</i> de <i>malware</i> (alta entropía). La latencia y proporción indican escaneo o exfiltración.

Logs de Sistema/Aplicación (Texto)	Secuencia de <i>syscalls</i> ejecutadas, Frecuencia de comandos inusuales, Códigos de respuesta HTTP.	Codificación (<i>One-Hot Encoding</i> ⁶), TF-IDF (para texto), Análisis de N-gramas.	El <i>One-Hot Encoding</i> se usa para valores categóricos (protocolos, puertos). TF-IDF pondera la rareza de las palabras clave o secuencias en el conjunto total de logs.
Binarios (Malware Analysis)	Tamaño del binario, Número de librerías importadas, Puntos de entrada, Sección con mayor entropía.	Conversión a vectores (<i>Embedding</i>), Representación de <i>heatmap</i> (para CNN), Codificación de Metadatos Estáticos.	Los metadatos estáticos proporcionan una visión rápida de las intenciones del código. Las <i>features</i> dinámicas (<i>syscalls</i> en <i>sandbox</i>) son críticas para capturar el comportamiento de ejecución.

2.2. Entrenamiento y Evaluación del Modelo: El Contexto Operacional

Durante el entrenamiento, un desafío recurrente en ciberseguridad es el **desequilibrio de clases**, ya que los eventos maliciosos constituyen una fracción minúscula del tráfico total. Esto requiere técnicas específicas (como SMOTE o el ajuste de pesos de clase) para evitar que el modelo clasifique todo simplemente como "benigno."

La evaluación de modelos en un entorno de Centro de Operaciones de Seguridad (SOC) requiere que las métricas reflejen el impacto real en la carga de trabajo del analista, yendo más allá de la mera precisión académica.²

Tabla 2: Métricas de Evaluación Críticas y su Significado Operacional en un SOC

Métrica	Fórmula Técnica	Significado Operacional (SOC)
Recall (Tasa de Verdaderos Positivos)		Prioridad de Seguridad: Mide la capacidad del modelo para detectar <i>todos</i> los ataques reales. Un bajo <i>Recall</i> implica que las amenazas pasan desapercibidas.
Precision		Prioridad del Analista: Mide qué proporción de las alertas generadas son realmente ataques. Una baja <i>Precision</i> significa que el tiempo del analista se desperdicia en <i>Falsos Positivos</i> .
F1-Score		Equilibrio: Proporciona un equilibrio entre la necesidad de no perder ataques y la necesidad de reducir la carga del analista.

False Positive Rate (FPR)		Medida de Fatiga: Es la métrica más sensible. Un alto FPR incrementa la "fatiga de alerta," minando la confianza del equipo en el sistema de IA y su usabilidad. ¹
----------------------------------	--	--

En el contexto operativo de un SOC, existe una tensión fundamental entre el *Recall* y la *Precision*. Aunque desde una perspectiva de seguridad pura se desearía un *Recall* del 100% (no perder ningún ataque), un sistema con un *Recall* perfecto que genere un gran volumen de falsos positivos (bajo *Precision* / alto FPR) es inutilizable. La fatiga de alerta conduce a la desensibilización del analista. Por lo tanto, en muchos sistemas de detección, se prioriza una **alta Precision** y un **FPR aceptablemente bajo**, incluso si esto implica sacrificar ligeramente el *Recall* para mantener la confianza ⁷ y la capacidad operativa del equipo.

Además, la utilidad del modelo depende de que el conjunto de datos de entrenamiento refleje de manera continua el "mundo real" de las amenazas. Si los datos no son representativos, el modelo desarrollará un sesgo que perjudicará su capacidad de generar resultados esperados contra ataques novedosos.⁷

2.3. Detección de Anomalías y Comportamientos Sospechosos

La detección de anomalías utiliza modelos no supervisados como *Isolation Forest* o *Autoencoders* para el *baselining*. Estos modelos aprenden el perfil de lo que es "normal" en el entorno (tráfico de red, patrones de acceso a archivos, comandos de *endpoint*). Cualquier evento que no encaje en este perfil o que genere un alto error de reconstrucción (en el caso de los *Autoencoders*) es marcado como anomalía.

Esta aproximación es intrínsecamente efectiva para la detección de **vulnerabilidades de día cero** ¹ porque el sistema no requiere conocimiento previo de la firma del ataque, sino solo de la desviación del estado estable.

- Aplicación Clave: UEBA (User and Entity Behavior Analytics):
El UEBA se enfoca en perfilar la actividad de usuarios y entidades (servidores,

dispositivos). Modelos de ML analizan métricas como la hora de inicio de sesión, el volumen de datos descargados o los recursos accedidos. La detección de anomalías en UEBA identifica desviaciones, como un empleado que repentinamente accede a bases de datos críticas a horas inusuales o desde una ubicación geográfica diferente. Esto es crucial para la identificación temprana de credenciales comprometidas o amenazas internas, que a menudo siguen a una explotación inicial exitosa.

3. Impacto Operacional y Automatización

El ML no solo mejora la detección, sino que se convierte en un motor para la toma de decisiones estratégicas y la respuesta automatizada en el ciclo de *Security Operations*.

3.1. Predicción de Amenazas y Vulnerabilidades

El ML proporciona una capa predictiva que permite a las organizaciones anticipar y priorizar riesgos de manera más efectiva:

- **Predicción Basada en Indicadores de Compromiso (IoCs):** Los modelos supervisados pueden correlacionar los IoCs conocidos (direcciones IP, *hashes*, dominios) con el comportamiento de la infraestructura interna y las tendencias globales para predecir la probabilidad de un ataque dirigido al sector o región de la organización.
- **Prioritización de Parches más allá del CVSS:** El *Common Vulnerability Scoring System* (CVSS) proporciona una puntuación de severidad teórica. El ML añade el contexto operacional necesario para la toma de decisiones. Los modelos predictivos pueden estimar la **explotabilidad real** de una vulnerabilidad. Estos modelos incorporan *features* como la disponibilidad de código de explotación (*Proof of Concept* - PoC) público, el nivel de dificultad para la explotación o si la vulnerabilidad está siendo activamente utilizada en la naturaleza (por ejemplo, en el catálogo de Vulnerabilidades Explotadas Conocidas de CISA). Al priorizar los parches basándose en el riesgo real y la actividad de los atacantes, las organizaciones pueden optimizar sus recursos limitados de respuesta.

3.2. Automatización de Respuestas a Incidentes (SOAR)

La magnitud de las amenazas impulsadas por la IA hace que la defensa manual o

semi-automatizada sea insuficiente.¹ La integración del ML en plataformas

SOAR (*Security Orchestration, Automation, and Response*) es indispensable para escalar la respuesta.

- **Clasificación y Triage Impulsados por ML:** El ML automatiza el proceso de clasificación de alertas, que consume mucho tiempo, al correlacionar cientos de alertas dispares en hallazgos de ataques coherentes (*Attack Discovery*).¹ Esto reduce drásticamente el ruido de las alertas, permitiendo que los equipos de seguridad se concentren únicamente en las amenazas genuinas y prioricen los incidentes más críticos en función de su severidad e impacto potencial.¹
- **Enriquecimiento de Datos y Asistencia al Analista:** El ML y la IA generativa se utilizan para enriquecer los datos automáticamente, consultando inteligencia de amenazas y bases de datos internas. Además, el uso de IA conversacional y *frameworks* de agentes (como se ve en las plataformas de seguridad modernas) genera automáticamente consultas complejas, resume incidentes, explica la evidencia de los modelos de ML y recomienda los siguientes pasos de respuesta.¹
- **Respuesta Automatizada:** El ML es el motor que ejecuta acciones predefinidas de forma automática para acelerar la respuesta a incidentes.¹ Esto incluye tareas críticas como el aislamiento inmediato de *hosts* comprometidos, el bloqueo de direcciones IP maliciosas o la ejecución de rutinas de remediación de vulnerabilidades.¹

La eficiencia de estos sistemas de automatización depende críticamente de la **latencia** del modelo de ML. Si el procesamiento del dato de seguridad masivo (*Big Data*) es lento, la acción de contención (por ejemplo, aislar un servidor) se ejecuta tarde, anulando el valor de la automatización. Por lo tanto, el rendimiento y la escalabilidad de los algoritmos son cuellos de botella operacionales cruciales.⁷

La automatización de tareas rutinarias eleva el rol del analista de seguridad. El enfoque se traslada de la clasificación táctica de alertas a la validación de la salida del ML, la caza de amenazas (*Threat Hunting*), y el diseño y refinamiento de *playbooks* estratégicos.

4. Desafíos Adversarios y de Implementación

La madurez del ML en ciberseguridad trae consigo la necesidad de abordar sus propias vulnerabilidades. Los sistemas defensivos basados en ML son susceptibles a la manipulación por parte de adversarios que entienden cómo funcionan los algoritmos.

4.1. El Desafío de la Ciberseguridad Ofensiva (*Adversarial ML*)

Dado el *background* en explotación de sistemas, es crucial entender que el ML desplaza el punto de ataque del *software* al **dato**. La vulnerabilidad más crítica reside a menudo en el conjunto de datos y en la frontera de decisión del modelo.

Ataques Adversarios (*Evasion Attacks*)

En la fase de inferencia (cuando el modelo está en producción), el atacante busca evadir la detección. Esto se logra generando una muestra maliciosa—por ejemplo, un *exploit* o un *payload*—con **mínimas perturbaciones estratégicas**. Estas modificaciones, a menudo imperceptibles para un humano, son suficientes para empujar la representación del dato de entrada justo fuera de la frontera de decisión del clasificador, haciendo que el modelo lo clasifique erróneamente como benigno.

Un ejemplo práctico es la ofuscación de *malware* modificando la secuencia de bytes o reordenando funciones de manera que las *features* extraídas (como los N-gramas o los metadatos) no coincidan con los patrones aprendidos por el modelo.

Envenenamiento de Datos (*Poisoning Attacks*)

En la fase de entrenamiento, el atacante busca comprometer la integridad del modelo. Los ataques de envenenamiento inyectan datos falsos o muestras maliciosas etiquetadas incorrectamente (por ejemplo, *malware* etiquetado como "tráfico legítimo") en el conjunto de entrenamiento.

Si el atacante logra inyectar suficientes muestras envenenadas, el modelo resultante desarrollará un sesgo que lo hará incapaz de detectar ese tipo particular de ataque en el futuro. Este ataque es sofisticado y subraya la necesidad de asegurar y controlar estrictamente el origen y la integridad de los datos de entrenamiento.⁷

Tabla 4: Desafíos del Adversarial ML y Mitigación

Tipo de Ataque Adversario	Fase del ML	Objetivo del Atacante	Estrategia de Mitigación Recomendada	
Evasión (Evasion)	Inferencia (Producción)	Lograr que el modelo clasifique el ataque como benigno mediante perturbaciones sutiles.	Entrenamiento Adversarial (exponer al modelo a ejemplos adversarios), Detección de Anomalías de Entrada.	
Envenenamiento (Poisoning)	Entrenamiento y Re-entrenamiento	Comprometer la integridad y la precisión a largo plazo del modelo inyectando datos falsos.	Auditoría Estricta de Datos ⁷ , Modelos de	Integridad de Datos (No Supervisados), Certificación de la Fuente de los datos.

Para contrarrestar estos ataques, la **Defensa Híbrida** es esencial. Esto incluye técnicas puramente tecnológicas, como hacer que los modelos sean más robustos mediante el *Entrenamiento Adversarial*, y medidas de gobernanza, como el desarrollo de estándares, regulaciones y mejores prácticas para el control de datos.⁷

4.2. Desafíos de Implementación

La adopción de ML en ciberseguridad enfrenta barreras prácticas significativas más allá de los ataques ofensivos:

Escalabilidad y Latencia

El ML debe operar en la escala de *Big Data* de seguridad. El volumen masivo de datos de red⁷ requiere una infraestructura de procesamiento distribuido y algoritmos eficientes. Si un modelo complejo de *Deep Learning* introduce latencia, la detección en tiempo real se vuelve inalcanzable, lo que reduce la eficacia de toda la cadena de respuesta de SOAR. La latencia es un factor de fracaso operacional.

Disponibilidad de Datos y *Labeling*

La dificultad para obtener conjuntos de datos etiquetados de alta calidad es un cuello de botella persistente.⁷ Los incidentes de seguridad reales son raros, lo que dificulta el entrenamiento de modelos supervisados. Además, etiquetar miles de millones de eventos de red de manera manual es ineficiente o imposible. Esto obliga a las organizaciones a depender fuertemente de modelos no supervisados para la detección, aceptando inherentemente un mayor riesgo de Falsos Positivos.

Desafíos Éticos, de Sesgo y Explicabilidad (XAI)

Existe una tensión entre la complejidad del modelo y la confianza. La exageración de las capacidades de la IA/ML por parte de los proveedores ha generado escepticismo en la comunidad de seguridad.⁷ Para que los analistas confíen en un sistema de IA que toma decisiones de contención crítica, el modelo no puede ser una "caja negra."

- **Explicabilidad (XAI):** La necesidad de modelos transparentes, justos y auditables es crucial.⁷ Si un modelo genera una alerta, el analista debe poder auditar el razonamiento detrás de la clasificación (por ejemplo, qué *features* específicas del binario o del log causaron la clasificación maliciosa). Sin XAI, la confianza en el sistema es baja, lo que puede llevar a que los analistas ignoren o deshabiliten los sistemas automáticos.

La paradoja es que las arquitecturas más potentes para el análisis de datos complejos (CNN/RNN) son las más difíciles de auditar. El futuro requiere una investigación intensa en XAI para modelos profundos que mitiguen los ataques de evasión y refuercen la confianza

operativa.

Conclusiones y Recomendaciones para el Analista

El Machine Learning no es una solución mágica, sino una herramienta de escalabilidad y precisión indispensable para la ciberseguridad moderna. Su dominio es crucial para el futuro Analista de Ciberseguridad.

1. **Enfoque de la Defensa Centrado en el Comportamiento:** El ML traslada la defensa de las firmas (basadas en conocimiento *a posteriori*) a la detección de anomalías y el *baselining* (basado en el comportamiento¹). El analista debe centrar sus habilidades no solo en qué buscar (IoCs), sino en cómo se ve el comportamiento *normal* del sistema.
2. **La Importancia Crítica del Dato:** La habilidad más valiosa para un futuro analista de ML en seguridad será el *Feature Engineering*.⁶ Entender la estructura interna de los logs, los paquetes y los binarios, y saber qué *features* extraídos realmente impactan la clasificación, es lo que diferencia a un buen implementador de ML de un mero usuario de *frameworks*.
3. **Priorización Operacional de Métricas:** En el SOC, la reducción de la fatiga de alerta y la alta usabilidad (alta *Precision* y bajo FPR) son a menudo más valiosos que un *Recall* marginalmente superior. Los sistemas deben ser configurados para generar alertas de alta confianza que el analista pueda investigar de manera eficiente.¹
4. **Dominio de la Ofensiva para la Defensa:** Dada la experiencia en *hacking ético*, el estudiante debe aplicar la mentalidad de explotación a los modelos de ML. El conocimiento de cómo funcionan los ataques de *evasión* y *envenenamiento* es esencial para diseñar y validar defensas robustas, mediante el entrenamiento adversarial y la implementación de mecanismos XAI. El analista debe ser el principal auditor de la integridad de los datos de entrenamiento para prevenir el *poisoning*.⁷
5. **Adopción de SOAR y Escalabilidad:** El ML es el motor de la automatización de la respuesta. El analista debe prepararse para trabajar con plataformas SOAR, entendiendo cómo el ML clasifica y prioriza incidentes, y cómo la baja latencia del modelo es fundamental para la contención efectiva.¹

Obras citadas

1. Guía completa sobre la IA en ciberseguridad | Elastic, fecha de acceso: octubre 1, 2025, <https://www.elastic.co/es/what-is/ai-cybersecurity>
2. Aplicación del machine learning en la detección de intrusiones para ..., fecha de acceso: octubre 1, 2025, <https://e-spacio.uned.es/entities/publication/1d6011b1-3eb9-4d3c-9e6b-22e2d78>

[8e5ef](#)

3. Aplicación de algoritmos Random Forest y XGBoost en una base de solicitudes de tarjetas de crédito - SciELO México, fecha de acceso: octubre 1, 2025, https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S1405-774320200003000002
4. Random Forest - SVM | Caso práctico 1. - YouTube, fecha de acceso: octubre 1, 2025, <https://m.youtube.com/watch?v=AQCcrnoNGYCQ>
5. Arquitecturas de Modelos de IA: CNNs, RNNs y Transformadores - Focalx, fecha de acceso: octubre 1, 2025, <https://focalx.ai/es/inteligencia-artificial-es/arquitecturas-de-modelos-de-ia-cnns-rnns-y-transformadores/>
6. Técnicas, importancia y aplicación de "Feature-Engineering" en ..., fecha de acceso: octubre 1, 2025, <https://disenet.com/tecnicas-importancia-y-aplicacion-de-feature-engineering-en-machine-learning/>
7. IA/ML en ciberseguridad: desafíos, oportunidades y avances, fecha de acceso: octubre 1, 2025, <https://stellarcyber.ai/es/unlocking-the-potential-of-ai-ml-in-cybersecurity-challenges-opportunities-and-progress-indicators/>